




Variáveis correlacionadas

Correlação Linear

- Correlação \Rightarrow dependência, mas dependência \nRightarrow correlação



Correlação Linear

- Correlação \Rightarrow dependência, mas dependência \nRightarrow correlação



Correlação Linear

- Correlação \Rightarrow dependência, mas dependência \nRightarrow correlação




$$\rho_{XY} = \frac{Cov[X, Y]}{\sqrt{Var[X]}\sqrt{Var[Y]}} = \frac{X \cdot Y}{\|X\| * \|Y\|} = \cos \alpha_{XY}$$

Teoria de Cóopulas

- Estrutura de dependência;
- Mais genérica do que a correlação (que se resume a um único tipo de cópula);
- Bem como consiste em um método que cria estrutura de dependências entre distribuições marginais, a fim de criar uma distribuição conjunta.


Tipo de Cópulas

- Cópula Independente;



Tipo de Cóopulas


- Cópula Independente;
- **Cópula gaussiana;**



EXEMPLO - MATLAB

Tipo de Cóopulas

- Cópula Independente;
- Cópula gaussiana;
- Cópula de Plackett (c);
- Cópula de Frank (d);
- Cópula de Clayton (e – f);



PCE – Para variáveis não independentes

- A teoria do PCE indica a necessidade de variáveis independentes. Então, como lidar quando as variáveis não são independentes?
 - (i) Ignorar a correlação das variáveis;
 - (ii) Através de transformações isoprobabilísticas, transformar duas variáveis dependentes em duas variáveis independentes;
 - (iii) Construir um PCE com polinômios arbitrários, que sejam ortogonais às distribuições marginais do problema.

PCE – Para variáveis não independentes

- A teoria do PCE indica a necessidade de variáveis independentes. Então, como lidar quando as variáveis não são independentes?
 - (i) Ignorar a correlação das variáveis;
 - (ii) **Através de transformações isoprobabilísticas, transformar duas variáveis dependentes em duas variáveis independentes;**
 - (iii) Construir um PCE com polinômios arbitrários, que sejam ortogonais às distribuições marginais do problema.

PCE – Para variáveis não independentes

- A teoria do PCE indica a necessidade de variáveis independentes. Então, como lidar quando as variáveis não são independentes?
- (i) Ignorar a correlação das variáveis;
- (ii) Através de transformações isoprobabilísticas, transformar duas variáveis dependentes em duas variáveis independentes;
- (iii) Construir um PCE com polinômios arbitrários, que sejam ortogonais às distribuições marginais do problema.


Métodos Globais

- Método de Morris
- Índices de Borgonovo
- Índices Sobol
- Índices ANCOVA
- Índices Kucherenko
- Método de Cotter*

Índices Sobol

$$Y = \mathcal{M}(X)$$

Supõe que o modelo pode ser decomposto em HDMR



$$Y = \mathcal{M}_0 + \sum_{i=1}^M \mathcal{M}_i(x_i) + \sum_{1 \leq i \leq j \leq M}^M \mathcal{M}_{ij}(x_i, x_j) + \cdots + \mathcal{M}_{1,2,\dots,M}(x_1, x_2, \dots, x_M)$$

ANCOVA – Análise de Covariância

- Li e Rabitz (2010) indicam que é possível a decomposição de variâncias para variáveis correlacionadas. No entanto, a variância total deixa de ser escrita em parcelas de variâncias, e passa a ser descrita por relações de covariância.

ANCOVA – Análise de Covariância

- Li e Rabitz (2010) indicam que é possível a decomposição de variâncias para variáveis correlacionadas. No entanto, a variância total deixa de ser escrita em parcelas de variâncias, e passa a ser descrita por relações de covariância.
- A partir desse HDMR, os índices ANCOVA são definidos da seguinte maneira:

$$S_i = \frac{Cov[\mathcal{M}_i(x_i), Y]}{Var[Y]} \Rightarrow S_i = \frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]} + \frac{Cov[\mathcal{M}_i(x_i), (Y - \mathcal{M}_i(x_i))]}{Var[Y]}$$

ANCOVA – Análise de Covariância

- Li e Rabitz (2010) indicam que é possível a decomposição de variâncias para variáveis correlacionadas. No entanto, a variância total deixa de ser escrita em parcelas de variâncias, e passa a ser descrita por relações de covariância.
- A partir desse HDNR, os índices ANCOVA são definidos da seguinte maneira:

$$S_i = \frac{Cov[\mathcal{M}_i(x_i), Y]}{Var[Y]} \Rightarrow S_i = \underbrace{\frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]}}_{S_i^U} + \underbrace{\frac{Cov[\mathcal{M}_i(x_i), (Y - \mathcal{M}_i(x_i))]}{Var[Y]}}_{S_i^C}$$

ANCOVA – Análise de Covariância

- Li e Rabitz (2010) indicam que é possível a decomposição de variâncias para variáveis correlacionadas. No entanto, a variância total deixa de ser escrita em parcelas de variâncias, e passa a ser descrita por relações de covariância.
- A partir desse HDMR, os índices ANCOVA são definidos da seguinte maneira:

$$S_i = \frac{Cov[\mathcal{M}_i(x_i), Y]}{Var[Y]} \Rightarrow S_i = \underbrace{\frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]}}_{S_i^U} + \underbrace{\frac{Cov[\mathcal{M}_i(x_i), (Y - \mathcal{M}_i(x_i))]}{Var[Y]}}_{S_i^C}$$

- Caniou (2012) sugere o uso de PCEs para a construção do HDMR no cálculo de índices ANCOVA.

ANCOVA – Análise de Covariância

- Os índices totais ficariam:

$$S_i^{U,T} = \frac{Var[\mathcal{M}_{i \in u}(x_i)]}{Var[Y]}$$

$$S_i^{C,T} = \frac{Cov[\mathcal{M}_{i \in u}(x), \mathcal{M}_{i \notin v}(x)]}{Var[Y]}$$

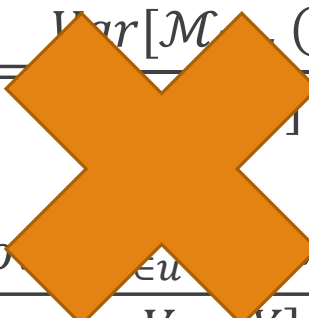
ANCOVA – Análise de Covariância

- Os índices totais ficariam:

$$S_i^{U,T} = \frac{Var[\mathcal{M}_{i \notin v}(x_i)]}{Var[Y]}$$
$$S_i^{C,T} = \frac{Cov[\mathcal{M}_{i \notin v}(x), \mathcal{M}_{i \notin v}(x)]}{Var[Y]}$$

ANCOVA – Análise de Covariância

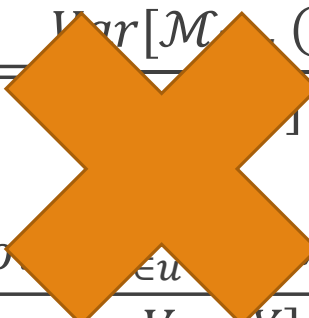
- Os índices totais ficariam:

$$S_i^{U,T} = \frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]}$$

$$S_i^{C,T} = \frac{Cov[\mathcal{M}_i(x_i), \mathcal{M}_{i \notin v}(x)]}{Var[Y]}$$

$$S_i = S_i^U + S_i^I + S_i^C = \frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]} + \frac{Cov[\mathcal{M}_i(x_i), \mathcal{M}_{i \in u}(x)]}{Var[Y]} + \frac{Cov[\mathcal{M}_i(x_i), \mathcal{M}_{i \notin v}(x)]}{Var[Y]}$$

ANCOVA – Análise de Covariância

- Os índices totais ficariam:

$$S_i^{U,T} = \frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]}$$

$$S_i^{C,T} = \frac{Cov[\mathcal{M}_i(x_i), \mathcal{M}_{i \notin v}(x)]}{Var[Y]}$$

$$S_i = S_i^U + S_i^I + S_i^C = \frac{Var[\mathcal{M}_i(x_i)]}{Var[Y]} + \frac{Cov[\mathcal{M}_i(x_i), \mathcal{M}_{i \in u}(x)]}{Var[Y]} + \frac{Cov[\mathcal{M}_i(x_i), \mathcal{M}_{i \notin v}(x)]}{Var[Y]}$$

Métodos Globais

- Método de Morris
- Índices de Borgonovo
- Índices Sobol
- Índices ANCOVA
- Índices Kucherenko
- Método de Cotter*

Método de Kucherenko

- Utiliza a lei da variância total para definir uma nova metodologia de partição da variância total. Isso permite escrever a variância total como:

$$\text{Var}[Y] = \text{Var}_i[E_{\sim i}[Y|X_i]] + E_i[\text{Var}_{\sim i}[Y|X_i]]$$

$$1 = \underbrace{\frac{\text{Var}_i[E_{\sim i}[Y|X_i]]}{\text{Var}[Y]}}_{S_i} + \underbrace{\frac{E_i[\text{Var}_{\sim i}[Y|X_i]]}{\text{Var}[Y]}}_{S_{\sim i}^T}$$

Método de Kucherenko

$$S_i^T = \frac{E_{\sim i}[Var_i[Y|X_i]]}{Var[Y]}$$

$$S_i = \frac{Var_i[E_{\sim i}[Y|X_i]]}{Var[Y]}$$

Estes valores podem ser estimados através de um loop duplo de Monte Carlo!